

パターン認識と機械学習

第2章 確率分布

橋本龍二

December 28, 2020

1

2

3 ガウス分布

3.1 条件付きガウス分布

x をガウス分布に従う D 次元ベクトルとする。

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \sim N(\mathbf{x} | \boldsymbol{\mu}, \Sigma)$$

ただし、 \mathbf{x}_a は M 個、 \mathbf{x}_b は $D - M$ 個の要素。

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

ただし、 Σ_{aa} と Σ_{bb} は対称だが $\Sigma_{ba} = {}^T \Sigma_{ab}$ である。また、 $\Lambda = \Sigma^{-1}$ とすれば、

$$\Lambda = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix}$$

ただし、 Λ_{aa} と Λ_{bb} は対称だが、 ${}^T \Lambda_{ab} = \Lambda_{ba}$ である。また Σ_{aa} の逆行列は Λ_{aa} ではないので注意。

このように考えれば、 $p(x)$ とは \mathbf{x}_a と \mathbf{x}_b の同時分布である。 $\mathbf{x}_a | \mathbf{x}_b$ の条件付

き分布を考える。

$$\begin{aligned}
{}^T(\mathbf{x} - \boldsymbol{\mu})\Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) &= {}^T \begin{pmatrix} \mathbf{x}_a - \boldsymbol{\mu}_a \\ \mathbf{x}_b - \boldsymbol{\mu}_b \end{pmatrix} \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix} \begin{pmatrix} \mathbf{x}_a - \boldsymbol{\mu}_a \\ \mathbf{x}_b - \boldsymbol{\mu}_b \end{pmatrix} \\
&= {}^T(\mathbf{x}_a - \boldsymbol{\mu}_a)\Lambda_{aa}(\mathbf{x}_a - \boldsymbol{\mu}_a) + {}^T(\mathbf{x}_a - \boldsymbol{\mu}_b)\Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\
&\quad + {}^T(\mathbf{x}_b - \boldsymbol{\mu}_b)\Lambda_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a) + {}^T(\mathbf{x}_b - \boldsymbol{\mu}_b)\Lambda_{bb}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\
&= {}^T\mathbf{x}_a\Lambda_{aa}\mathbf{x}_a - {}^T\mathbf{x}_a\Lambda_{aa}\boldsymbol{\mu}_a + {}^T\mathbf{x}_a\Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\
&\quad - {}^T\boldsymbol{\mu}_a\Lambda_{aa}\mathbf{x}_a + {}^T(\mathbf{x}_b - \boldsymbol{\mu}_b)\Lambda_{ba}\mathbf{x}_a + const \\
&= {}^T\mathbf{x}_a\Lambda_{aa}\mathbf{x}_a - {}^T\mathbf{x}\{\Lambda_{aa}\boldsymbol{\mu}_a - \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b)\} \\
&\quad - \{{}^T\boldsymbol{\mu}_a\Lambda_{aa} - {}^T(\mathbf{x}_b - \boldsymbol{\mu}_b)\Lambda_{ba}\}\mathbf{x}_a + const \\
&= {}^T\mathbf{x}_a A^{-1} \mathbf{x}_a - {}^T\mathbf{x}_a B - {}^T B \mathbf{x}_a + const \\
&= {}^T(\mathbf{x}_a - AB)A^{-1}(\mathbf{x}_a - AB) + const
\end{aligned}$$

ただし、

$$A = \Lambda_{aa}^{-1}, \quad B = \Lambda_{aa}\boldsymbol{\mu}_a - \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b)$$

と置いた。したがって、条件付き分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ の平均と分散をそれぞれ $\boldsymbol{\mu}_{a|b}$, $\Sigma_{a|b}$ とすると、

$$\begin{aligned}
\boldsymbol{\mu}_{a|b} &= \Lambda_{aa}^{-1}\{\Lambda_{aa}\boldsymbol{\mu}_a - \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b)\} \\
&= \boldsymbol{\mu}_a - \Lambda_{aa}^{-1}\Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\
\Sigma_{a|b} &= \Lambda_{aa}^{-1}
\end{aligned}$$

となる。では $\Lambda_{aa}^{-1}, \Lambda_{ab}$ を求めよう (このままの方が簡潔なので普通は求めない)。今、

$$\begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}^{-1} = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix}$$

であるから、

$$\begin{aligned}
\Lambda_{aa} &= (\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1} \\
\Lambda_{ab} &= -(\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1}\Sigma_{ab}\Sigma_{bb}^{-1}
\end{aligned}$$

より、

$$\begin{aligned}\boldsymbol{\mu}_{a|b} &= \boldsymbol{\mu}_a + \Sigma_{ab}\Sigma_{bb}^{-1}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ \Sigma_{a|b} &= \Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba}\end{aligned}$$

となった。条件付き分布の平均は \mathbf{x}_b の線形関数。

3.2 周辺ガウス分布

3.1 の設定のもとで周辺分布 $p(\mathbf{x}_a)$ を求める。

$$\begin{aligned}p(\mathbf{x}_a) &= \int p(\mathbf{x}_a, \mathbf{x}_b) d\mathbf{x}_b \\ &\propto \int \exp\left\{-\frac{1}{2} {}^T(\mathbf{x} - \boldsymbol{\mu})\Lambda(\mathbf{x} - \boldsymbol{\mu})\right\} d\mathbf{x}_b \\ &\quad {}^T(\mathbf{x} - \boldsymbol{\mu})\Lambda(\mathbf{x} - \boldsymbol{\mu}) \\ &= {}^T(\mathbf{x}_a - \boldsymbol{\mu}_a)\Lambda_{aa}(\mathbf{x}_a - \boldsymbol{\mu}_a) + {}^T(\mathbf{x}_a - \boldsymbol{\mu}_b)\Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ &\quad + {}^T(\mathbf{x}_b - \boldsymbol{\mu}_b)\Lambda_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a) + {}^T(\mathbf{x}_b - \boldsymbol{\mu}_b)\Lambda_{bb}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ &= {}^T\mathbf{x}_b\Lambda_{bb}\mathbf{x}_b + {}^T\mathbf{x}_b\Lambda_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a) - {}^T\mathbf{x}_b\Lambda_{bb}\boldsymbol{\mu}_b - {}^T\boldsymbol{\mu}_b\Lambda_{bb}\mathbf{x}_b + {}^T(\mathbf{x}_a - \boldsymbol{\mu}_a)\Lambda_{ab}\mathbf{x}_b \\ &\quad + {}^T\mathbf{x}_a\Lambda_{aa}\mathbf{x}_a - {}^T\boldsymbol{\mu}_a\Lambda_{aa}\mathbf{x}_a - {}^T\mathbf{x}_a\Lambda_{aa}\boldsymbol{\mu}_a - {}^T\boldsymbol{\mu}_b\Lambda_{ab}\boldsymbol{\mu}_b - {}^T\boldsymbol{\mu}_b\Lambda_{ba}\mathbf{x}_a + const \\ &= {}^T\mathbf{x}_b\Lambda_{bb}\mathbf{x}_b - {}^T\mathbf{x}_b\{\Lambda_{bb}\boldsymbol{\mu}_b - \Lambda_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a)\} - \{{}^T\boldsymbol{\mu}_b\Lambda_{bb} - {}^T(\mathbf{x}_a - \boldsymbol{\mu}_a)\Lambda_{ab}\}\mathbf{x}_b \\ &\quad + {}^T\mathbf{x}_a\Lambda_{aa}\mathbf{x}_a - {}^T\mathbf{x}(\Lambda_{aa}\boldsymbol{\mu}_a + \Lambda_{ab}\boldsymbol{\mu}_b) - ({}^T\boldsymbol{\mu}_a\Lambda_{aa} + {}^T\boldsymbol{\mu}_b\Lambda_{ba})\mathbf{x}_a + const \\ &= {}^T\mathbf{x}_b A^{-1} \mathbf{x}_b - {}^T\mathbf{x}_b B - {}^T B \mathbf{x}_b \\ &\quad + {}^T\mathbf{x}_a\Lambda_{aa}\mathbf{x}_a - {}^T\mathbf{x}(\Lambda_{aa}\boldsymbol{\mu}_a + \Lambda_{ab}\boldsymbol{\mu}_b) - ({}^T\boldsymbol{\mu}_a\Lambda_{aa} + {}^T\boldsymbol{\mu}_b\Lambda_{ba})\mathbf{x}_a + const \\ &= {}^T(\mathbf{x}_b - AB)A^{-1}(\mathbf{x} - AB) - {}^T B {}^T AB \\ &\quad + {}^T\mathbf{x}_a\Lambda_{aa}\mathbf{x}_a - {}^T\mathbf{x}(\Lambda_{aa}\boldsymbol{\mu}_a + \Lambda_{ab}\boldsymbol{\mu}_b) - ({}^T\boldsymbol{\mu}_a\Lambda_{aa} + {}^T\boldsymbol{\mu}_b\Lambda_{ba})\mathbf{x}_a + const\end{aligned}$$

ただし、

$$A = \Lambda_{bb}^{-1}, \quad B = \Lambda_{bb}\boldsymbol{\mu}_b - \Lambda_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a)$$

と置いた。ゆえ、

$$p(\mathbf{x}_a) \propto \exp\left[-\frac{1}{2}\left\{-^T B^T A B + ^T \mathbf{x}_a \Lambda_{aa} \mathbf{x}_a - ^T \mathbf{x} (\Lambda_{aa} \boldsymbol{\mu}_a + \Lambda_{ab} \boldsymbol{\mu}_b) - (^T \boldsymbol{\mu}_a \Lambda_{aa} + ^T \boldsymbol{\mu}_b \Lambda_{ba}) \mathbf{x}_a\right\}\right]$$

右辺の指数部分の中身を変形してまとめると、

$$\begin{aligned} & ^T \mathbf{x}_a (-^T \Lambda_{ba} \Lambda_{bb}^{-1} \Lambda_{ba} + \Lambda_{aa}) \mathbf{x}_a \\ & - ^T \mathbf{x}_a (-^T \Lambda_{ba} \boldsymbol{\mu}_b - ^T \Lambda_{ba} \Lambda_{bb}^{-1} \Lambda_{ba} \boldsymbol{\mu}_a + \Lambda_{aa} \boldsymbol{\mu}_a + \Lambda_{ab} \boldsymbol{\mu}_b) \\ & - (^T \boldsymbol{\mu}_b \Lambda_{ba} \mathbf{x}_a - ^T \boldsymbol{\mu}_a ^T \Lambda_{ba} \Lambda_{bb}^{-1} \Lambda_{ba} + ^T \boldsymbol{\mu}_a \Lambda_{aa} + ^T \boldsymbol{\mu}_b \Lambda_{ab}) \mathbf{x}_a \\ = & ^T \mathbf{x}_a B^{-1} \mathbf{x}_a - ^T \mathbf{x}_a C - ^C \mathbf{x}_a \\ = & ^T (\mathbf{x}_a - BC) B^{-1} (\mathbf{x}_a - BC) + const \end{aligned}$$

ただし、

$$\begin{aligned} B &= (\Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba})^{-1} \\ C &= (\Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba}) \boldsymbol{\mu}_a \end{aligned}$$

したがって、

$$\begin{aligned} \boldsymbol{\mu}_{a|b} &= BC = \boldsymbol{\mu}_a \\ \Sigma_{a|b} &= B = \Sigma_{aa} \end{aligned}$$

3.3 ガウス変数に対するベイズの定理

ベクトル \mathbf{x} を正規分布に従う確率変数とし、平均が \mathbf{x} の線形関数で共分散が \mathbf{x} とは独立であるようなガウス条件付き分布 $p(\mathbf{y}|\mathbf{x})$ を考える。すなわち、

$$\begin{cases} p(\mathbf{x}) = N(\mathbf{x}|\boldsymbol{\mu}, \Lambda^{-1}) \\ p(\mathbf{y}|\mathbf{x}) = N(\mathbf{y}|A\mathbf{x} + \mathbf{b}, L^{-1}) \end{cases}$$

同時分布を求めるため、 $\mathbf{z} = \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix}$ とおく。

$$p(\mathbf{z}) = p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x})p(\mathbf{y}|\mathbf{x})$$

なので、対数をとって、

$$\begin{aligned}
\log p(\mathbf{z}) &= \log p(\mathbf{x}) + \log p(\mathbf{y}|\mathbf{x}) \\
&\propto {}^T(\mathbf{x} - \boldsymbol{\mu})\Lambda(\mathbf{x} - \boldsymbol{\mu}) + {}^T(\mathbf{y} - A\mathbf{x} - \mathbf{b})L(\mathbf{y} - A\mathbf{x} - \mathbf{b}) + const \\
&= {}^T\mathbf{x}\Lambda\mathbf{x} + {}^T\mathbf{x}{}^TALAx + {}^T\mathbf{y}\mathbf{Ly} - {}^T\mathbf{x}{}^TALy - {}^T\mathbf{y}LAx \\
&\quad - {}^T\mathbf{x}\Lambda\boldsymbol{\mu} - {}^T\boldsymbol{\mu}\Lambda\mathbf{x} + {}^T\mathbf{x}{}^TALb + {}^T\mathbf{b}LAx - {}^T\mathbf{y}Lb - {}^T\mathbf{b}Ly + const \\
&= {}^T\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \begin{pmatrix} \Lambda + {}^TALA & - {}^TAL \\ - LA & L \end{pmatrix} \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \\
&\quad - {}^T\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \begin{pmatrix} \Lambda\boldsymbol{\mu} - {}^TALb \\ Lb \end{pmatrix} - {}^T\begin{pmatrix} \Lambda\boldsymbol{\mu} - {}^TALb \\ Lb \end{pmatrix} \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} + const \\
&= {}^T\mathbf{z}R\mathbf{z} - {}^T\mathbf{z}B - {}^TB\mathbf{z} + const \\
&= {}^T(\mathbf{z} - R^{-1}B)R(\mathbf{z} - R^{-1}B) + const
\end{aligned}$$

より、 \mathbf{z} のガウス分布の精度行列は、

$$R = \begin{pmatrix} \Lambda + {}^TALA & - {}^TAL \\ - LA & L \end{pmatrix}$$

したがって、分散共分散行列は

$$\Sigma_{\mathbf{z}} = R^{-1} = \begin{pmatrix} \Lambda^{-1} & \Lambda^{-1} {}^TA \\ A\Lambda^{-1} & L^{-1} + A\Lambda^{-1} {}^TA \end{pmatrix}$$

平均は、

$$\begin{aligned}
\boldsymbol{\mu}_{\mathbf{z}} &= \begin{pmatrix} \Lambda^{-1} & \Lambda^{-1} {}^TA \\ A\Lambda^{-1} & L^{-1} + A\Lambda^{-1} {}^TA \end{pmatrix} \begin{pmatrix} \Lambda\boldsymbol{\mu} - {}^TALb \\ Lb \end{pmatrix} \\
&= \begin{pmatrix} \boldsymbol{\mu} \\ A\boldsymbol{\mu} + \mathbf{b} \end{pmatrix}
\end{aligned}$$